

AI 기반 이상 행동 탐지 시스템 개발 프로젝트

＊

YOLOv8과 LSTM Autoencoder를 활용한 실시간 이상 행동 탐지 및 분석

2026.07.01

발표자 : 김종록

목차

* 01	* 02	* 03
프로젝트 배경 및 목표 - 프로젝트 배경 및 필요성 - 목표 및 기대 효과	시스템 구성 - 전체 시스템 아키텍처 - 주요 구성 요소 및 흐름도	데이터 및 전처리 - 데이터셋 구성 및 특성 - 전처리 과정 및 방법론
* 04	* 05	* 06
AI 모델 아키텍처 - YOLOv8 객체 탐지 - LSTM Autoencoder 이상 탐지	성능 분석 및 최적화 - 성능 지표 및 임계값 시뮬레이션 - 실패 사례 분석	문제 해결 및 결론 - Hybrid Rule 및 EMA 적용 - 프로젝트 성과 및 향후 계획

프로젝트 배경 및 목표

프로젝트 추진 배경

- 교통 모니터링의 한계 극복: 기존의 단순 차량 카운팅이나 육안 감시만으로는 심야 시간대의 돌발 상황이나 예측 불가능한 교통 체증 (Anomaly)에 즉각적으로 대응하기 어려움.
- 시계열(Sequence) 기반 분석의 필요성 대두: 순간적인 화면(프레임)뿐만 아니라, 과거 교통 흐름의 맥락(Context)을 기억하고 분석하여 선제적으로 위험을 경고할 수 있는 고도화된 AI 솔루션이 필수적.
- 실시간 처리 속도와 정확도의 딜레마: 고화질 고속도로 CCTV 영상을 렉 없이 초당 30프레임으로 처리하면서도, 동시에 복잡한 딥러닝 연산을 수행해야 하는 기술적 난제 존재.

목표 및 기대 효과

- 초고속 객체 탐지 파이프라인 구축: 가장 가볍고 빠른 YOLOv8 Nano 모델을 채택하여 실시간 차량(Car, Bus, Truck) 탐지 및 밀집도 분석의 지연(Latency) 문제 해결.
- LSTM Autoencoder 기반 지능형 이상 탐지: 시간의 흐름을 기억하는 LSTM 모델을 도입하여, 단순 밀집도가 아닌 '흐름 상의 비정상적 트래픽 패턴'을 스스로 학습하고 탐지하는 시스템 개발.
- 오탐지(False Alarm) 최소화 방어 로직 완비: 도메인 지식을 반영한 Hybrid 룰(야간 동적 튜닝 등)과 EMA(지수 이동 평균) 필터를 융합하여 실무에 즉각 투입 가능한 수준의 높은 신뢰도 확보.
- 실시간 클라우드 웹 관제 대시보드(MLOps) 구축: 로컬 스크립트를 넘어, Supabase DB와 Streamlit을 연동하여 장소에 구애받지 않고 실시간 통계 및 알람을 모니터링하는 완성형 웹 대시보드 서비스 배포.


시스템 개요

AI 분석 모델 구축 프로세스



1. 데이터 수집

- 고속도로 CCTV HLS 스트리밍 연동
- 트래픽 로그(traffic_features.csv) 원천 데이터 확보



2. 데이터 전처리

- OpenCV 기반 영상 프레임 추출 및 최적 해상도 리사이징
- 학습 데이터 스케일링(정규화) 및 시계열(Sequence) 텐서 변환



3. 모델링

- 가장 가벼운 YOLOv8 Nano 객체 탐지 모델 도입
- 과거 흐름을 기억하는 LSTM Autoencoder 설계



4. 예측

- YOLOv8 모델을 통한 실시간 차량 객체 탐지 및 도로 밀집도 도출
- LSTM 모델의 재구성 오차(Reconstruction Error)를 통한 이상치(Anomaly Score) 판단



5. 인사이트

- 상위 1~40% 구간 시뮬레이션을 통한 최적의 알람 임계값(Threshold) 설정 가이드 제공
- Supabase & Streamlit 연동으로 직관적인 실시간 교통 관제 시각화 대시보드 구축

원천 데이터 수집 및 라벨링 전처리

- 방대한 원천 데이터(Raw Data): AI Hub 'CCTV 교통 데이터' 등 4.8GB 규모의 수십만 장 JPG 프레임 획득
- 복잡한 라벨 구조: 객체의 위치 좌표가 매우 복잡하고 무거운 COCO 포맷(JSON) 형태로 제공됨
- 라벨 파싱 및 변환(Preprocessing): YOLOv8이 빠르게 학습할 수 있도록 가벼운 TXT 포맷으로 스크립트를 짜서 일괄 변환
- 노이즈 타겟 필터링: 승용차, 버스, 트럭 등 핵심 3대 클래스만 추출하고, 관제 목적과 무관한 보행자 등은 선제적으로 제거

```
dataset/  
├── 1.Training/  
│   ├── images/ (수십만 장의 CCTV 원본 JPG)  
│   └── labels/ (객체 바운딩 박스 COCO JSON)  
└── 2.Validation/  
    ├── images/ (검증용 JPG 프레임)  
    └── labels/ (검증용 JSON 포맷 정답지)
```

학습용 정형 데이터(CSV) 추출 및 구축

■ 오프라인 모델 학습(Offline Training) 데이터 구축

● 구축 배경: 실시간 클라우드 관제 시스템을 가동하기에 앞서, 인공지능(LSTM)의 뇌를 학습시킬 방대한 양의 '과거 시계열 데이터셋' 확보가 필수적임

● 비정형 데이터의 정형화: 4.8GB에 달하는 수십만 장의 방대한 CCTV 원본 영상(비정형 데이터)을 YOLOv8 탐지 엔진에 모두 통과시켜 데이터 정제 시작

■ 특징 추출(Feature Extraction) 및 데이터 적재

● 시계열 피쳐 추출: 모든 프레임에서 실시간으로 승용차(Car), 버스(Bus), 트럭(Truck)의 객체 수를 Count 하고, 이를 기반으로 도로의 혼잡도를 나타내는 '밀집도(Density)' 파생 변수를 수학적으로 산출

정형 데이터(csv) 구축: 추출된 메타데이터들을 시간 순서대로 엮어 ****traffic_features.csv****라는 거대한 시계열 정형 데이터베이스로 최종 구축 (이 거대한 csv 데이터를 바탕으로 LSTM 챔피언 모델을 학습시킴)

timestamp	frame_id	car_count	bus_count	truck_count	density
2026-06-01 0:00	0	21	2	7	0.445
2026-06-01 0:00	1	19	1	2	0.27
2026-06-01 0:00	2	21	2	6	0.42
2026-06-01 0:00	3	24	3	3	0.405
2026-06-01 0:00	4	19	2	4	0.35
2026-06-01 0:00	5	19	3	5	0.405
2026-06-01 0:00	6	24	1	4	0.37
2026-06-01 0:00	7	22	2	1	0.305
2026-06-01 0:00	8	18	3	7	0.445
2026-06-01 0:00	9	21	2	7	0.445
2026-06-01 0:00	10	18	1	4	0.31
2026-06-01 0:00	11	18	2	6	0.39
2026-06-01 0:00	12	20	3	4	0.39
2026-06-01 0:00	13	14	3	3	0.305
2026-06-01 0:00	14	14	1	5	0.295
2026-06-01 0:00	15	18	2	2	0.29
2026-06-01 0:00	16	17	2	6	0.38
2026-06-01 0:00	17	21	1	3	0.315
2026-06-01 0:00	18	17	3	1	0.285
2026-06-01 0:00	19	15	1	0	0.18
2026-06-01 0:01	20	24	1	4	0.37
2026-06-01 0:01	21	19	1	5	0.345
2026-06-01 0:01	22	20	1	7	0.405
2026-06-01 0:01	23	15	1	1	0.205

피쳐 엔지니어링 및 텐서 변환

- 신규 파생 변수(Feature) 창출: 탐지된 단순 차량 대수(Count)를 활용하여, 해당 프레임의 도로 혼잡도를 수학적으로 수치화한 '밀집도(Density)' 파생 변수 도출

- 시계열(Sequence) 최적화: 엑셀 같은 평범한 2차원(행/열) 데이터 구조 탈피

- 3차원 텐서(Tensor) 가공: 1초 전, 2초 전의 과거 흐름을 LSTM이 기억할 수 있도록 (샘플 수, 시간 스텝, 피쳐 수) 형태의 3차원 시퀀스 텐서로 데이터 최종 가공 완료

	car_count	bus_count	truck_count	density
0	4	1	0	0.012296
1	10	1	0	0.025451
2	1	0	0	0.001720
3	8	0	0	0.025386
4	10	1	0	0.051062

AI 모델 설계 (1) - YOLOv8 기반 객체 탐지

- YOLOv8 벤치마크 테스트: CCTV 영상 프레임에서 차량(Car/Bus/Truck)을 실시간 탐지하기 위해 Nano, Small, Medium 3종 모델의 속도(FPS)와 정확도(mAP) 다중 비교
- 트러블슈팅: 정확도가 가장 높은 Medium 모델의 경우, 초당 30프레임(30fps) 실시간 환경에서 심각한 렉(Lag) 유발
- 최종 챔피언 (YOLOv8 Nano): 고속도로 환경 특성상 차량 객체가 커서 가장 가벼운 Nano 모델로도 정확도가 훌륭히 방어됨을 확인.
연산량을 대폭 줄여 남은 자원을 LSTM에 집중하는 아키텍처 확립



AI 모델 설계 (2) - YOLOv8 탐지 임계값(Threshold) 최적화

Confidence: 0.25



Confidence: 0.5



Confidence: 0.75



문제 정의: 실시간 고속도로 CCTV 특성상 빛 반사, 가로등 그림자 등으로 인해 차량을 오인식(False Positive)하거나 놓치는(False Negative) 문제 발생 가능성 존재

실험 설계: AI가 객체를 '차량'으로 확인하는 기준 점수(Confidence)를 0.25 / 0.50 / 0.75 세 구간으로 나누어 시각적 벤치마크 수행

■ 시뮬레이션 결과 및 최종 결정

- 0.25 (저신뢰도): 그림자나 노이즈까지 차량으로 오탐지(FP)하여 밀집도(Density) 수치를 비정상적으로 뿔튀기시키는 부작용 발생
- 0.75 (고신뢰도): 화면 멀리 있거나 서로 겹쳐있는 실제 차량들을 놓치는 미탐지(FN) 발생
- 최종 세팅 (0.50): 과탐지와 미탐지 사이의 균형이 가장 안정적인 0.50을 최종 객체 탐지 임계값으로 픽스(Fix)하여 원천 데이터의 신뢰도 완벽 확보

AI 모델 설계 (3) - 이상 데이터 분포 탐색 (3D PCA)

- 시각화 기법 도입: 4차원(Car, Bus, Truck, Density)으로 구성된 트래픽 피쳐(Feature) 데이터의 구조를 한눈에 파악하기 위해 3차원 PCA(주성분 분석) 시각화 수행


- 분포도 시각화 결과: 파란색 점(정상 데이터)과 빨간색 점(이상 데이터)을 3D 공간상에 투영시켜 군집 형태 확인

- 분석 인사이트 및 모델링 방향성 확립

- 비선형적 혼재 현상: 정상 상황과 비정상 상황의 경계선이 칼로 자르듯 명확하지 않고, 공간상에 매우 복잡하고 비선형적으로 얽혀 있음을 눈으로 확인

- 알고리즘 방향성 도출: 데이터가 이토록 얽혀 있으므로, 단순한 1차원적 임계값 컷오프(Cut-off)나 거리 기반 알고리즘으로는 탐지율에 한계가 뚜렷할 것임을 선제적으로 증명

- 결론: 고차원 패턴을 파악할 수 있는 고도화된 머신러닝/딥러닝 모델의 필요성 강력 대두



AI 모델 설계 (4) - 베이스라인 모델 테스트 (K-Means)

- 도입 배경: 앞선 PCA에서 확인한 복잡한 데이터 분포를, 가장 직관적이고 기본적인 '거리 기반' 군집화 알고리즘이 얼마나 잘 분류해 내는지 기준점(Baseline)을 잡기 위해 선행 도입
- 탐지 원리: 학습된 정상 군집의 중심(Centroid)으로부터 들어온 데이터가 얼마나 멀리 떨어져 있는지를 계산하여, 거리가 멀면 이상(Anomaly)으로 판단

■ 동적 임계값(Threshold) 시뮬레이션

- 고정값의 한계 돌파: 임의로 알람 기준을 정하지 않고, 상위 1%부터 40% 구간까지 임계값을 촘촘하게 변경해 가며 성능(F1-Score) 변화율 추적
- 최적점 도출: 가장 높은 F1-Score를 달성하는 최적의 임계값(Threshold)을 자동으로 찾아내는 시뮬레이션 파이프라인 구현 성공

K-Means Classification Report:

	precision	recall	f1-score	support
0.0	0.74	1.00	0.85	846
1.0	1.00	0.30	0.46	424
accuracy			0.77	1270
macro avg	0.87	0.65	0.66	1270
weighted avg	0.83	0.77	0.72	1270

■ 모델의 치명적 한계점 (한계 분석)

- 한계 원인: K-Means는 현재 들어온 1프레임의 '단순 수치'와 '거리'만 비교할 뿐, 이전 상황이 어땠는지(과거의 흐름)를 전혀 기억하지 못함
- 실패 결론: 트럭이 잠깐 지나가거나 화면이 살짝 떨리는 단순 노이즈에도 거리가 멀어졌다고 알람을 울려버리는 잦은 오탐지(False Positive) 문제 발생 확인

AI 모델 설계 (5) - 중간 고도화 (MLP Autoencoder)


● 모델 변경: K-Means의 비선형적 한계를 극복하기 위해 다층 퍼셉트론(MLP) 기반의 딥러닝 신경망 모델 도입

● 핵심 원리 (재구성 오차): 오직 '정상' 교통 흐름 데이터만으로 신경망을 학습시킴. 이후 새로운 영상이 들어왔을 때 모델이 이를 제대로 복원(Reconstruct)하지 못하고 오차(MSE)가 크게 튀면 이상(Anomaly)으로 간주하는 핵심 로직 확립

■ 2차 한계점 발현 (여전히 남은 숙제)

● 차원의 한계 (2차원 Tensor): MLP 신경망은 비선형 구조 파악에는 뛰어났으나, 여전히 개별 프레임 단위(samples, features)의 데이터만 '독립적'으로 처리하는 근본적 한계 존재

● 맥락(Context)의 부재: 바로 1초 전 도로 상황이 어땠는지를 기억하지 못해, 카메라 앞을 큰 버스가 훑 지나가는 정상적인 상황에도 오차가 급증하여 알람을 울리는 약점 노출



AI 모델 설계 (6) - 최종 모델 선정 (LSTM Autoencoder)

● 시계열 처리: 앞선 모델들의 '단기 기억 상실' 문제를 완벽히 해결하기 위해, 3차원 시퀀스 텐서 (samples, time_steps, features)를 처리하는 LSTM 레이어 전격 설계

● 탐지 메커니즘: 직전 교통 흐름을 뇌에 기억한 상태에서 현재 프레임을 판단하므로, 카메라 앞을 큰 버스가 가리는 순간적인 현상도 비정상인 아닌 '정상적인 흐름'으로 똑똑하게 인지함

■ 하이퍼파라미터 튜닝 및 챔피언 등극


● 은닉층(Hidden State) 튜닝: 모델의 뇌 크기에 해당하는 뉴런 개수를 8, 16, 32개로 끈질기게 조작하며 하이퍼파라미터 비교 실험 수행

● 과적합(Overfitting) 억제: 32개 뉴런 적용 시, 학습 데이터에 너무 과하게 맞춰져 실제 환경에서 오히려 분산이 커지는 치명적 현상 발견


● 최종 결론: 가장 밸런스가 뛰어나고 이상 징후를 날카롭게 잡아내는 **'16-Neuron LSTM Autoencoder'**를 최종 메인 엔진으로 탑재 완료

LSTM 하이퍼파라미터 튜닝 시작...

-> 뉴런 8개 모델 훈련 중... [완료] F1-Score: 0.4615
-> 뉴런 16개 모델 훈련 중... [완료] F1-Score: 0.4598
-> 뉴런 32개 모델 훈련 중... [완료] F1-Score: 0.4615



성능 분석 (1) - Confusion Matrix 및 지표



■ 관제 시스템 특화 평가지표 (Metrics)

- 재현율(Recall) 최우선 지표: 실제 발생한 사고를 단 하나라도 놓치면(미탐) 대형 참사로 이어지므로, 재현율을 최우선 지표로 삼아 모델을 평가함
- F1-Score 밸런싱: 재현율을 극한으로 높이느라 알람이 너무 빈번하게 울리는(오탐) 것을 막기 위해, 정밀도(Precision)와의 조화 평균인 F1-Score를 지속 모니터링함

■ Confusion Matrix (혼동 행렬) 분석

- 우수한 탐지력: 실제 위험 상황(TP)과 원할한 흐름(TN)을 명확하게 분리하고 식별해 냄
- 한계점 발견 (다음 장 빌드업): 재현율을 높이다 보니, 야간 빛 반사나 대형 트럭의 순간 가림 현상을 '정체'로 오인하는 가짜 알람(False Positive, FP)이 일부 발생하는 현상 관찰됨

성능 분석 (2) - ROC Curve 및 식별력(AUC)


■ ROC Curve (수신자 조작 특성 곡선)

● 평가 방법론: 모델이 비정상(Anomaly)을 얼마나 잘 숙아내는지 알아보기 위해, 오탐지율(FPR) 대비 정탐지율(TPR)의 비율을 곡선으로 도식화하여 검증

■ AUC (Area Under Curve) 결과

● 압도적 분류 성능 증명: 모델 성능이 1점 만점에 가까울수록 그래프가 좌측 상단으로 가파르게 치솟음.

● 결과치 해석: 대각선 점선(단순 찍기, Random 확률)을 아득히 뛰어넘어 좌상단에 찰각 붙어있는 궤적을 보여주며, 우리 챔피언 모델이 가진 딥러닝 본연의 압도적인 식별력을 수치적으로 완벽하게 입증함



[최종 모델 종합 스코어보드]

1. K-Means Clustering	AUC: 0.9575	최적 F1-Score: 0.8905
2. MLP Autoencoder	AUC: 0.8685	최적 F1-Score: 0.7099
3. LSTM Autoencoder	AUC: 0.9422	최적 F1-Score: 0.8371


최종 결과물 - 실시간 시계열 이상 탐지 대시보드

■ Streamlit 시연

● 클라우드 실시간 시각화: Supabase DB에 초 단위로 적재되는 교통 밀집도 데이터를, LSTM 챔피언 모델이 실시간으로 추론(Inference)하여 웹 대시보드(Streamlit) 화면에 표출

■ 직관적인 이상 행동 알람 (Red Zone)

● 동적 임계값 적용: 단순히 밀집도가 높다고 울리는 것이 아닌, 모델의 재구성 오차(Reconstruction Error)가 임계값을 초과할 경우 해당 지점을 즉각 ****비정상(빨간 점)****으로 띄워 관제사에게 경고 알람 발생




실패 사례 분석 (1)

■ False Positive (오탐지 - 정상을 사고로 착각함)

- 야간 헤드라이트 빛 번짐: 야간 시간대 차량의 강한 헤드라이트 빛 반사를 YOLO가 유령 차량(Ghost)으로 겹쳐서 오인식하여, 순간적으로 밀집도(Density)가 폭증해 알람이 울리는 현상
- 대형 객체의 시야 가림: 카메라 렌즈 바로 앞을 대형 화물 트럭이 훅 지나갈 때, 도로 전체가 가려지면서 LSTM이 이를 비정상적인 흐름 패턴으로 착각하는 현상

■ 예시 사진



실패 사례 분석 (2)

■ False Negative (미탐지 - 실제 사고를 놓침)

- 원거리 픽셀 뭉개짐: CCTV 화각의 한계상 너무 멀리서 발생한 접촉 사고의 경우, 객체가 픽셀 단위로 뭉개져 앞서 설정한 탐지 임계값(Confidence 0.5)을 넘지 못해 모델이 아예 인식조차 못 하는 현상

- 초장기 점진적 정체: 명절 귀성길처럼 수십 분에 걸쳐 아주 서~서히 차가 막히는 경우, LSTM 모델이 이 느린 변화를 '새로운 정상 흐름'으로 적응해 버려서 경고를 놓치는 현상

■ 예시 사진



Trouble Shooting (1) 데이터 파이프라인 병목 극복

■ 문제 발생: 대규모 데이터 적재 시 메모리 뺨음(Crash) 현상


● 증상: 4.8GB 분량의 CCTV 분석 결과를 로컬 엑셀(CSV) 파일에 담아 딥러닝 모델에 밀어 넣으려 했으나, 로컬 PC의 메모리 과부하(OOM)로 인해 시스템 셧다운(Crash) 현상 지속 발생

● 원인 분석: 실시간으로 끊임없이 무한대로 누적되는 고속도로 트래픽 로그를, 고정된 파일(CSV)로 감당하려는 아키텍처 자체의 구조적 결함 확인

■ 해결 완료 (Solution): 실시간 MLOps 아키텍처 전면 개조

● 구조 개편: 구시대적인 로컬 파일 시스템을 과감하게 폐기

● 클라우드 도입: YOLO가 분석한 로그를 즉시 Supabase 실시간 클라우드 DB에 쏴 올리고, 분석 모델(LSTM)은 클라우드에서 최신 데이터를 실시간으로 당겨오는 라이브 파이프라인으로 뜯어고쳐 병목 현상 완벽 해결



id	created_at	car_count	bus_count	truck_count
501	2026-06-29 17:29:21.476358+00	4	1	0
502	2026-06-29 17:29:21.476358+00	10	1	0
503	2026-06-29 17:29:21.476358+00	1	0	0
504	2026-06-29 17:29:21.476358+00	8	0	0
505	2026-06-29 17:29:21.476358+00	10	1	0
506	2026-06-29 17:29:21.476358+00	1	1	1
507	2026-06-29 17:29:21.476358+00	4	0	1
508	2026-06-29 17:29:21.476358+00	3	2	0
509	2026-06-29 17:29:21.476358+00	5	3	0
510	2026-06-29 17:29:21.476358+00	5	2	1
511	2026-06-29 17:29:21.476358+00	5	0	0
512	2026-06-29 17:29:21.476358+00	3	2	1

Trouble Shooting (2) 실시간 AI 추론 속도 딜레이 극복

■ 문제 발생: 실시간 환경에서의 추론 딜레이(Lag) 및 끊김

● 증상: 객체 탐지 정확도가 뛰어난 YOLOv8 Medium 모델을 실제 관제 카메라(30fps)에 연결하자, 영상이 심각하게 버벅대며 똑똑 끊기는 프레임 드랍 발생

● 원인 분석: 고화질 영상을 실시간으로 연산하기에는 Medium 모델의 딥러닝 파라미터가 너무 무거워, 1프레임을 분석하는 데 걸리는 딜레이(Inference Time)가 한계치를 초과함

■ 해결 완료 (Solution): 최적의 리소스 분배 전략 확립

● 도메인 지식 활용: 고속도로 환경상 차량(객체)이 크고 뚜렷하게 보인다는 점을 이용, 가장 가벼운 YOLOv8 Nano 모델로 스위칭하여 속도(FPS)를 10배 이상 끌어올리면서도 정확도 하락은 완벽히 방어함

● 선택과 집중: YOLO 연산에서 극단적으로 아낀 컴퓨팅 자원을, 전체 시스템의 메인 브레인인 '16-Neuron LSTM'에 전부 몰아주어 실시간 관제 최적화 달성



결론 및 한계점 (Conclusion & Future Works)

■ 프로젝트 핵심 성과 요약 (Conclusion)

● 완성형 파이프라인 구축: 객체 탐지(YOLO) → □ 시계열 이상 탐지(LSTM) → □ 클라우드 데이터 적재(Supabase) → □ 실시간 웹 시각화(Streamlit)로 이어지는 '지능형 실시간 교통 관제 풀스택 시스템' 구축 성공

■ 딥러닝의 물리적 한계점 (Limitations)

● 광원 노이즈 취약성: 딥러닝 모델의 뛰어난 성능에도 불구하고, 야간 시간대 강한 헤드라이트 빛 번짐이나 젖은 노면의 반사광을 차량으로 오인식하여 발생하는 가짜 알람(False Positive) 일부 잔존

● 일시적 시야 가림 현상: 대형 화물 트럭이나 버스가 카메라 렌즈 바로 앞을 스쳐 지나갈 때, 도로가 사라진 것으로 오인하는 픽셀 왜곡 한계 확인

■ 예시 사진



향후 발전 방향 (Future Works)

■ 상용화를 위한 시스템 고도화 로드맵 (Roadmap)

- Hybrid Rule (이중 방어 체계) 도입: AI의 맹목적인 판단에 의존하지 않고, "야간 시간에는 알람 임계값을 20% 올린다" 등 인간의 도메인 지식(규칙)을 딥러닝과 결합하여 한계점 완벽 극복 예정

- EMA 필터 (노이즈 스무딩) 적용: 카메라 떨림 등 순간적인 시야 가림으로 튀는 값을 막기 위해, 과거 데이터 평균을 반영하여 수치를 부드럽게 깎는 지수이동평균(EMA) 통계 기법 융합

- 엣지(Edge) 디바이스 배포 추진: 챔피언 모델을 추가 경량화하여, 무거운 중앙 서버 없이 고속도로 현장 CCTV 기기 자체에 탑재하는 진정한 의미의 상용화 최적화 검토



감사합니다.