

AI 기반 지능형 고속도로 로 관제 대시보드 개발

딥러닝 블랙박스 극복 및 LLM 기반 능동형 관제 시스템

2026.07.07

김종록

목차

1 프로젝트 개요

- 지능형 고속도로 이상탐지의 필요성

2 기존 딥러닝 접근 및 한계

- 기존 딥러닝 모델의 성능적 한계와 설명력 부실

3 확장 목표 및 시스템 구조

- End-to-End 파이프라인 아키텍처 및 기술 스택
- 데이터 전처리 및 시계열 윈도우 설계 근거

4 모델 구성 및 비교 기준

- LSTM Autoencoder 이상탐지 구조 및 평가 지표
- t+1 시계열 예측 모델 벤치마크 및 최종 선정

5 결과 및 시각적 사례 분석 (XAI)

- MSE 재구성 오차 분포 및 임계값(Threshold) 방어선
- SHAP 기반 정체 유발 핵심 변수(Feature) 규명

6 LLM 기반 지능형 관제 에이전트

- RAG 및 자율 도구 제어 기반 능동형 AI 에이전트
- RPA 기술 융합: 관제 보고서(.docx) 자동화
- 실시간 CCTV 비전 관제 및 자연어 조회 (Live 시연)

7 트러블 슈팅 및 문제 해결

- [Issue 1] 시연 중 클라우드 DB 오염 방지 아키텍처
- [Issue 2] LLM Function Calling 정보 왜곡 현상 버그 제어

8 결론 및 향후 계획

- 한계점 및 향후 계획
- 결론

프로젝트 개요

지능형 고속도로 이상탐지의 필요성

- 교통 관제 환경의 데이터적 특성
 - 출퇴근 시간에 집중되는 심한 데이터 불균형(Right-skewed) 패턴 발생
 - 돌발 사고 및 결함 데이터의 절대적 부족으로 인한 예측 난이도 상승
- 이상탐지 시스템의 목적
 - 예기치 못한 사고로 인한 추가적인 인명/재산 피해 방지
 - 교통 흐름 유지 및 관제 비용의 획기적 절감



기존 딥러닝 접근 및 한계


기존 딥러닝 모델의 성능적 한계와 설명력 부실

- 기존 접근 방식 (단순 객체 탐지)
 - YOLOv8 단일 모델은 실시간 속도는 빠르나, 시간의 흐름(Context)을 이해하지 못해 잦은 오탐 발생
- 기존 접근의 치명적 한계 (Black-box 현상)
 - 알람(Anomaly Score)은 울리지만, 왜 위험한지 판단 근거를 설명하지 못함
 - 관제사가 신뢰할 수 있는 '수학적/시각적 근거' 부재





확장 목표 및 시스템 구조

End-to-End 파이프라인 아키텍처 및 기술 스택



확장 목표 및 시스템 구조

데이터 전처리 및 시계열 윈도우 설계 근거




- 로그 변환 (Log-Transformation)의 논리적 근거
 - 고속도로 트래픽 특유의 심한 왜곡(Right-skewed)을 완화하기 위해 적용
 - 변환 후 StandardScaler를 적용하여 이상치(Outlier)에 대한 모델의 과적합 방지

- 시계열 윈도우 (Lookback Window) 설계
 - 과거 10 프레임(Lookback=10)의 흐름을 텐서(3D Shape)로 묶어 모델의 입력 데이터로 구성

모델 구성 및 비교 기준

LSTM Autoencoder 이상탐지 구조 및 평가 지표


- 병목(Bottleneck) 구조 설계 근거
 - 핵심 피처만 16-Neuron으로 압축(Encoding) 후 복원(Decoding)하여 정상 패턴을 학습하는 구조 채택
- 평가 지표 (Loss Metric)
 - 재구성 오차 측정을 위해 MSE(Mean Squared Error)를 Loss로 사용하여, 정상 패턴에서 벗어난 사고 프레임의 에러값을 극대화



모델 구성 및 비교 기준

t+1 시계열 예측 모델 벤치마크 및 최종 선정

모델명	R2-Score	평가 및 특징
1D-CNN	0.773	국소적 특징만 포착하여 장기 예측에 취약
LSTM	0.842	장기 기억력으로 가장 높은 예측력 달성
GRU	0.777	연산량 30% 감소 및 파라미터 최적화 달성




- GRU 최종 채택의 기술적 근거
- 점수가 미세하게 낮더라도, 관제 서버의 실시간 연산 부하(30FPS)를 최소화하기 위해 '경량화된 GRU' 채택

결과 및 시각적 사례 분석 (XAI)

MSE 재구성 오차 분포 및 임계값(Threshold) 방어



- 오차 분포의 시각적/수학적 분리:
 - 정상 교통량(파란색)과 돌발 사고/정체(빨간색) 구간의 재구성 오차 분포를 명확히 분리
- 임계값 설정의 근거:
 - 통계적 분석을 통해 명확한 탐지 임계값(Threshold 25.0)을 도출하여 시스템의 객관적 신뢰성 확보




결과 및 시각적 사례 분석 (XAI)

SHAP 기반 정체 유발 핵심 변수(Feature) 규




- 판단 근거의 투명성(Transparency) 확보:
- AI가 왜 해당 프레임을 '위험(Anomaly)'으로 판단했는지 그 '이유'를 역추적

- 핵심 원인 도출:
- 수많은 변수 중 '대형 트럭(Truck) 유입 급증' 등 특정 요소가 예측에 미친 기여도를 정량적으로 시각화



LLM 기반 지능형 관제 에이전트

RAG 및 자율 도구 제어 기반 능동형 AI 에이전트



```
[Agentic Workflow] LLM Function Calling Activated!


[*] Tool ID: 8d9g0tehj
[*] Target Function: get_traffic_data_from_db
[*] Payload Arguments:
{
  "query": "오늘 하루동안"
}

[Supabase DB Execution] SQL Equivalent Query
SELECT * FROM traffic_logs
WHERE created_at >= '2026-07-05T11:35:48.303219'
AND created_at <= '2026-07-06T11:35:48.303219'
ORDER BY id ASC LIMIT 1000;

[Database Response]
- Fetched Rows: 1000 rows
- Avg Density: 1.8%
- Max Density: 53.9%
- Anomaly Count: 7
```

LLM 기반 지능형 관제 에이전트

RPA 기술 융합: LLM 관제 보고서(.docx) 자동화



2026년 07월 06일 20시 40분 교통 관제 일시

1. 브리핑 개요

- 분석 시간 범위: 20시 30분 ~ 20시 40분 (10분간)
- 현재적인 교통 흐름 요약:
 - 출입 시간: 1000초
 - 평균 혼잡도: 1.3%로 상대적으로 원활한 교통 상태
 - 최대 혼잡도: 7.2%로 일시적인 혼잡이 발생하였지만 전체적으로는 안정적인 교통 상황

2. 혼잡도 상세 분석

등급	혼잡도
원활	0% ~ 5%
지체	5% ~ 10%
정체	10% 이상

- 평균 혼잡도(1.3%): 원활 등급에 해당, 교통 흐름이 원활한 것으로 판단
- 최대 혼잡도(7.2%): 원활 등급에 해당, 일시적인 혼잡이 발생하였지만 전체적으로는 안정적인 교통 상황

3. 특이사항 및 돌발 상황

지능형 교통 관제 일시

2026년 07월 06일 20시 40분 교통 관제 일시

1. 브리핑 개요

- 분석 시간 범위: 20시 30분 ~ 20시 40분 (10분간)
- 현재적인 교통 흐름 요약:
 - 출입 시간: 1000초
 - 평균 혼잡도: 1.3%로 상대적으로 원활한 교통 상태
 - 최대 혼잡도: 7.2%로 일시적인 혼잡이 발생하였지만 전체적으로는 안정적인 교통 상황

2. 혼잡도 상세 분석

[등급 | 혼잡도]

[--- | ---]

[원활 | 0% ~ 5%]

[지체 | 5% ~ 10%]

[정체 | 10% 이상]

*평균 혼잡도(1.3%): "원활" 등급에 해당, 교통 흐름이 원활한 것으로 판단

*최대 혼잡도(7.2%): "원활" 등급에 해당, 일시적인 혼잡이 발생하였지만 전체적으로는 안정적인 교통 상황

실시간 CCTV 딥러닝 비전 관제 (Live)

실시간 객체 추적 및 통행량 자동 계수 엔진

- 딥러닝 비전(YOLOv8) 실시간 트래킹:
 - 단순 객체 인식을 넘어, 차량의 연속적인 이동 궤적 (Trajectory)을 파란색 동선으로 시각화하여 차선 변경 및 감속 패턴 분석
- 가상 통제선(Virtual Line) 기반 차종별 계수:
 - 화면 중앙에 노란색 가상 통제선을 설정하고, 이를 통과하는 객체를 차종(승용차, 버스, 트럭)별로 실시간 카운팅하여 백엔드 DB에 자동 적재
- 야간 환경의 모델 강건성:
 - 조도가 낮고 헤드라이트 빛 번짐이 존재하는 야간 CCTV 환경에서도 다수의 차량을 안정적으로 탐지하여 통행량 계수 정확도 확보




LLM 기반 지능형 관제 에이전트

자연어 기반 DB 조회 및 정보 왜곡(거짓 정보) 차단 시연

- 관제사가 "최근 1시간 교통량 어때?"라고 자연어로 질문하면, LLM이 과거 DB를 스스로 조회하여 '평균 혼잡도', '차종별 대수', '이상 감지 횟수' 등 핵심 수치 요약 보고

시스템 신뢰성 확보 (정보 왜곡 방지):

- "7월 2일"과 같이 DB에 적재되지 않은 데이터를 요구할 경우, AI가 임의의 정보를 생성하지 않고 "기록이 존재하지 않아 조회가 불가능하다"고 답변하도록 예외 처리 로직 구현



트러블 슈팅 및 문제 해결


[Issue 1] 시연 중 클라우드 DB 오염 방지 아키텍처

- 문제 발생 (Problem)

- 시연용 '돌발 정체 주입(Stress Test)' 기능 작동 중, 시뮬레이션용으로 생성된 가상의 혼잡도 데이터가 클라우드 DB(Supabase)에 실시간 적재되어 전체 통계 로직에 오류가 발생하는 현상 발견.

- 문제 해결 (Solution)

- DB 비동기 적재 함수 호출 직전에 `stress\_test\_active` 상태를 검증하는 예외 처리문을 삽입함.
- 가짜 데이터가 도는 15프레임 동안은 DB 기록을 일시 정지(Pause)시키고, 시연 종료 즉시 실제 CCTV 데이터 적재를 자동 재개하는 안전한 백엔드 아키텍처로 개선 완료.



id	created_at
32283	2026-07-06 12:49:41.76557+00
32284	2026-07-06 12:49:42.8575+00
32285	2026-07-06 12:49:43.898736+00
32286	2026-07-06 12:49:45.039493+00
32287	2026-07-06 12:49:46.338457+00
32288	2026-07-06 12:49:47.375943+00
32289	2026-07-06 12:49:48.335894+00
32290	2026-07-06 12:49:50.671558+00
32291	2026-07-06 12:50:08.866851+00
32292	2026-07-06 12:50:10.748426+00
32293	2026-07-06 12:50:11.779982+00
32294	2026-07-06 12:50:13.668504+00
32295	2026-07-06 12:50:15.833587+00
32296	2026-07-06 12:50:17.128532+00

실제
SUPABASE DB에서
15프레임 동안
DB 기록 정지

트러블 슈팅 및 문제 해결

[Issue 2] LLM Function Calling 정보 왜곡 현상 버그 제어

- 문제 발생 (Problem)

- LLM이 과거 데이터를 직접 조회하는 Function Calling 수행 시, 경량 모델에서 잦은 에러(`tool\_use\_failed`) 및 정보 왜곡(거짓 정보) 현상 발생으로 정확한 과거 정보 RAG 검색이 불가능해짐.

- 문제 해결 (Solution)

- 에러가 잦은 모델을 폐기하고, 토큰 처리가 안정적인 대형 모델(Llama-3.3-70b)을 기본 탑재함.
- LLM이 시간 범위를 명확히 인식하도록 정규식 기반 시간 파서(Date Parser)를 백엔드에 구축.
- 추가로 클라우드 API 장애에 대비하여 Local LLM 연동 오프라인 롤백 기능을 마련하여 시스템 안정성 극대화.



한계점 및 향후 계획

프로젝트의 한계점 및 향후 계획



한계 1: 탐지 객체(CLASS)의 다양성 부족

- 한계점: 현재 승용차, 버스, 트럭 등 대형 차량 위주로 탐지하고 있어, 실제 교통사고 유발률이 높은 오토바이, 보행자 등의 소형 객체 탐지에는 제약이 있음.


- 향후 계획: 이륜차 및 보행자 이미지 학습 데이터를 추가 확보하여, 스쿨존이나 복잡한 교차로에서도 골목길 사고 예방이 가능하도록 탐지 범위 확장.



한계 2: LLM API 호출 지연 (LATENCY) 및 비용 문제

- 한계점: LLM이 실시간 데이터를 읽고 상황을 분석할 때마다 클라우드 API 통신 딜레이가 발생하며, 상시 호출 시 과금 비용 부담이 존재함.

- 향후 계획: 모든 상황에서 LLM을 호출하지 않고, 혼잡도 70% 초과나 '이상 상황(Anomaly)' 감지 시에만 LLM 보고서가 트리거(Trigger)되도록 로직을 개선하여 비용과 속도 최적화.



한계 3: 영상 스트리밍과 LLM 챗봇의 동시 실행(비동기 처리) 한계

- 한계점: 현재 프론트엔드(Streamlit)의 구조적 한계로 인해, CCTV 영상을 실시간 렌더링하는 동안에는 메인 스레드가 블로킹(Blocking)되어 LLM 채팅 기능을 동시에 사용할 수 없음.

- 향후 계획: 프론트엔드를 React.js와 FastAPI 웹소켓(WebSocket) 기반의 비동기 아키텍처로 전면 개편하여, 끊임 없는 영상 스트리밍과 LLM 관제 대화가 독립적(병렬)으로 동작하도록 고도화.

결론

결론 및 최종 기대 효과

데이터 기반의 AI 파이프라인 구축

- 비전 딥러닝 트래킹부터 LLM 기반 에이전트, DB 아키텍처, 트러블 슈팅까지 전 과정에 실무적 엔지니어링 근거 적용.

시스템 신뢰성(Trust) 확보

- AI의 판단 과정(수치화, 시각화)을 관제사가 투명하게 모니터링할 수 있도록 설계하여 Black-box 모델의 한계 극복.

비즈니스 임팩트

- 지능형 상황 전파 및 자동화된 문서 보고를 통해, 관제 인력의 업무 피로도를 경감하고 의사결정 '골든타임' 확보에 기여.

감사합니다.